Nader saeed

العنوان

التاريخ: / /

page1

Web Scraping

1- تحديد الهدف

- بناء نظام كامل يبدأ من # web scraping وينتهي كـ service
- عرض البيانات عبر API
- تشغيل النظام تلقائيا
- جعله قابل للتثبيت (web)

2- اختيار الموقع

طبعا الموقع الذي سنعمل له scraping سيكون موقع اقتباسات (quotes) لأنه يوفر لنا بيانات واضحة و سهلة من أجل تقليل التعقيد والتركيز على بناء النظام

3- تحديد البيانات المطلوبة

طبعا اختيار تحديد البيانات المطلوبة يعتمد على فائدة و أهمية هذه البيانات، و نحن هنا سوف نحدد البيانات التالية :

- النص (quote)
- المؤلف (author)
- التصنيفات (tags)

العنوان follow web scraping

التاريخ: page 2

4- تصميم Data Pipeline

1- مرحلة جمع البيانات (scraping)

2- مرحلة حفظ البيانات الخام

3- مرحلة تنظيف ومعالجة البيانات الخام.

4- مرحلة تخزين البيانات

5- مرحلة عرض البيانات عبر API

5- تصميم هيكل المشروع:

- من أجل تنظيم الكود ومرحلة التطوير، سوف نعتمد الهيكل التالي:

```
run.py   API/          data/          scraper/
         api.py        processed/     raw/          scraper.py
```

6- الأدوات والتقنيات:

- لغة البرمجة ← python
- تحليل html ← beautifulsoup (مكتبة)
- بناء API ← FastAPI
- تخزين البيانات ← JSON/CSV
- تشغيل الخدمة ← systemd
- تأمين النظام ← UFW
- إدارة packages ← apt/pip
- تنظيف ومعالجة ← pandas (مكتبة)

RTS
ثورة الحلول التقنية
Revolution of Technical Solutions

Follow

العنوان: web scraping

التاريخ: / /

Page 3

7- تصميم تدفق البيانات (Data Flow)

يبدأ البيانات من الموقع الإلكتروني، ثم يتم جمعها بواسطة Scraperab وحفظها كبيانات خام. بعد ذلك يتم تنظيفها ومعالجتها بواسطة مكتبة Pandas، ثم تخزينها في ملفات Son و CSV.

عند طلب المستخدم للبيانات، يقوم API بإرجاع البيانات له.

- ضمنا بأن هذا التصميم (data flow) من أجل تصميم النظام الخاص (جمع، معالجة، عرض) لتسهيل الفهم، حفظ البيانات كخام من أجل الحسب إعادة scraping.
- استخدام Son، CSV لسهولة التحليل وإعادة استخدام
- استخدام FastAPI لسرعة وسهولة بناء API.

8- تشغيل النظام الخاص service:

تشغيل API في الخلفية باستخدام System، تشغيل تلقائي عند بدء النظام.

9- تحديث النظام:

تتبع تحديث الطلوب باستخدام GEW

follow

العنوان: web scraping

التاريخ: / /

page 4

10 - تحويل المشروع إلى package :
- إنشاء package.deb
- تثبيت المشروع بسهولة
- تشغيل الخدمة تلقائياً

Data flow خطة

الموقع الإلكتروني

↓

scraper

↓

raw data

↓

Processing and cleaning

↓

Json / CSV storage

↓

FastAPI

↓

service

↓

package

يوضح هذا المخطط تدفق البيانات من مرحلة جمع البيانات حتى تشغيلها كحزمة جاهزة.

RTS